

# Global Terrorism Dataset

*Pedro Lisboa*

*10/16/2017*

## Contents

<b>Análise Exploratória Geral dos Dados</b>	<b>1</b>
América Central e Caribe . . . . .	7
América Central e Caribe . . . . .	8
Dados com agente desconhecido . . . . .	8
América do Sul . . . . .	9
<b>Análise dos incidentes envolvendo o Exército Provisório Irlandês (IRA)</b>	<b>10</b>
Estrutura do IRA e contexto do conflito durante as diferentes fases . . . . .	10
Eventos da segunda e quinta fase . . . . .	10
Fit da distribuição exponencial . . . . .	11
QQ-plot . . . . .	12
Teste de Kolmogorov-Smirnov . . . . .	13
Fit distribuição Gamma . . . . .	14
QQ-plots . . . . .	15
Teste de Kolmogorov-Smirnov . . . . .	16
Modelo de Hawkes . . . . .	17
<b>Referências</b>	<b>21</b>

## Trabalho do curso Estatística e Modelos Probabilísticos

Professora: Rosa Leão

```
library(data.table)
library(ggplot2)
library(stats)
library(stats4)

dt.gt <- fread(input = "./globalterrorismdb_0617dist.csv", colClasses = list('character' = 'eventid'))

##
Read 64.6% of 170350 rows
Read 170350 rows and 135 (of 135) columns from 0.141 GB file in 00:00:03
```

## Análise Exploratória Geral dos Dados

O Dataset observado contém informações sobre incidentes terroristas que ocorreram entre o ano de 1970 e 2016. A coleção possui um total de 170.350 entradas. Os dados foram coletados e são mantidos pelo National Consortium for the Study of Terrorism and Responses to Terrorism (START), uma agência governamental dos Estados Unidos. Cada entrada no banco de dados pode conter até 135 colunas preenchidas, apresentando desde o local, data e ator do ataque até o número de vítimas, o motivo e um indicador de sucesso (ou não). Nesse documento inicialmente será apresentado um resumo geral dos dados, analisando a quantidade de ataques por região e por tipo de arma utilizada. Vale ressaltar que os incidentes estudados foram executados

por agentes diferentes e em períodos diferentes da história e certos grupos podem possuir tendências sobre o padrão de ataques e o tipo de arma utilizada. Tendo isso em mente, a segunda parte do trabalho irá tentar extrair esses padrões a partir dos dados de atentados cometidos pelo Exército Republicano Irlandês, um grupo paramilitar que atuou no Reino Unido e Irlanda do Norte que atuou militarmente de 1969-1997.


```
g.hist.region <- ggplot(data = dt.gt, aes(factor(region_txt))) +
  geom_bar(position = "dodge", stat = 'count',
           color='#0099ff',fill='#33adff') +
  ylab('Número de incidentes') +
  xlab('Ano') +
  ggtitle("Quantidade de ataques separado por região") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 50, hjust = 1))

g.hist.success <- ggplot(data = dt.gt, aes(factor(attacktype1_txt),fill = factor(success))) +
  geom_bar(position = "fill", stat = 'count') +
  ylab('Densidade') +
  xlab('Ano') +
  labs(colour = 'Percentual de Atentados') +
  ggtitle("Percentual de Ataques bem Sucedidos") +
  #scale_x_continuous(breaks = seq(min(dt.gt$year),max(dt.gt$year),2)) +
  theme_minimal()+
  theme(axis.text.x = element_text(angle = 40, hjust = 1))

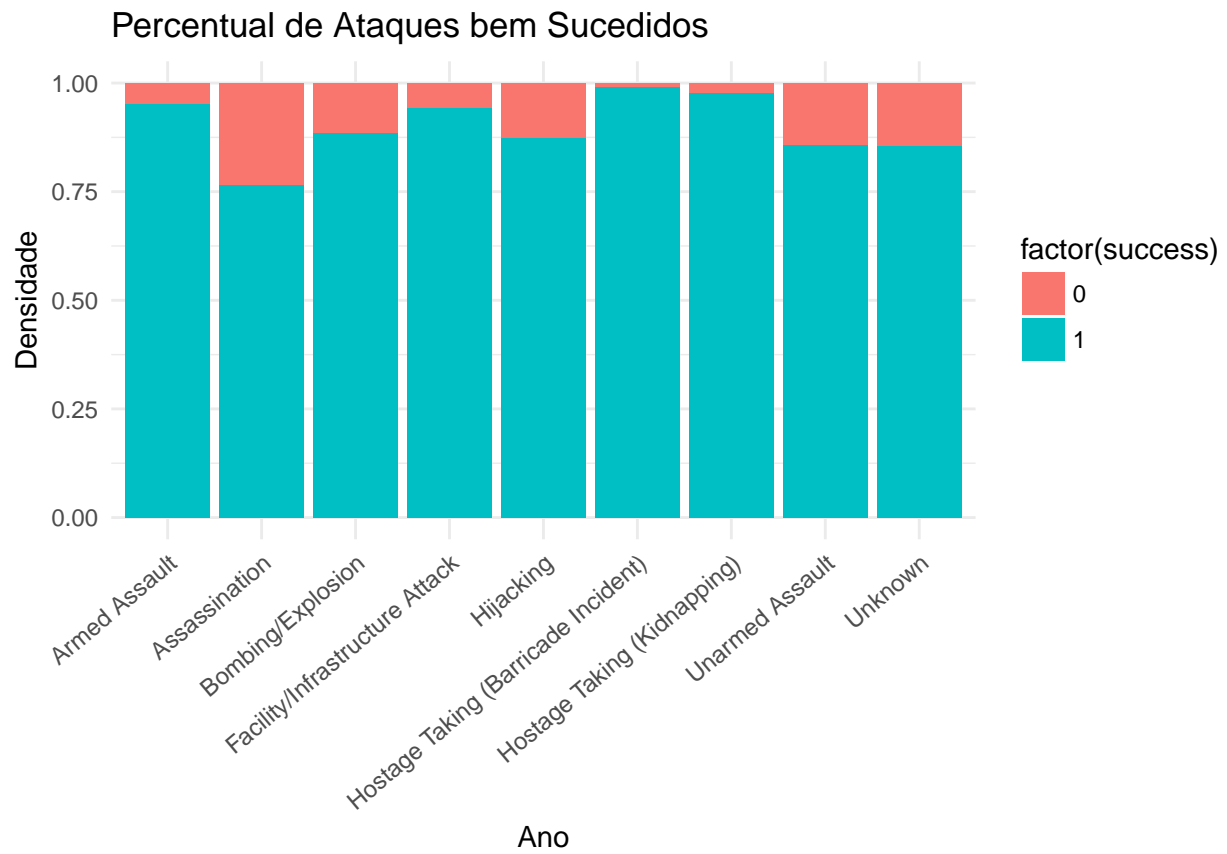
g.scatter.region <- ggplot(dt.gt[,.N,by=c('iyear','region_txt')],
  aes(x = iyear, y = N)) +
  geom_point(shape = 18, size = 2,colour = "#80bfff") +
  geom_line(colour = "#80bfff") +
  theme_minimal() +
  xlab('Ano') +
  ylab('Número de incidentes') +
  ggtitle("Contagem de ataques por ano separado por região") +
  facet_wrap(~region_txt)

g.scatter.type <- ggplot(dt.gt[,.N,by=c('iyear','attacktype1_txt')],
  aes(x = iyear, y = N)) +
  geom_point(shape = 18, size = 2,colour = "#80bfff") +
  geom_line(colour = "#80bfff") +
  xlab('Ano') +
  ylab('Número de incidentes') +
  ggtitle("Contagem de ataques por ano separado por tipo de arma utilizada") +
  theme_minimal() +
  facet_wrap(~attacktype1_txt)

show(g.hist.region)
```




```
show(g.hist.success)
```




```
show(g.scatter.region)
```

## Contagem de ataques por ano separado por região



`show(g.scatter.type)`

## Contagem de ataques por ano separado por tipo de arma utilizada




Os resultados acima indicam que a maior parte dos incidentes ocorre no Norte da África, Oriente Médio e sul asiático. Ao separarmos os ataques pela região onde ocorreram, pode-se observar que a intensidade de ocorrência de atentados depende diretamente do período histórico realizado. A partir desses resultados pode-se tentar correlacionar esse maior quantidade de incidentes em certos anos à eventos históricos marcantes nas regiões em que ocorreram: a maior parte dos ataques na América Central e Caribe ocorreu na década de 80, período de alta instabilidade política na região (q.v. Revolução Sandinista e caso Irã-Contras) e presença de regimes autoritários. Quase 30% dos atentados nessa região foram etiquetados como ação de Guerrilha - vale ressaltar que boa parte dos ataques não possui esse indicador. Não obstante, ao observar os atores destes, pode-se inferir que a natureza do ataque é de operações de guerrilha.

Os ataques terroristas no Oriente Médio e Norte da África ocorreram em sua maior parte no século XXI, o que está de acordo com a instabilidade política da região e grupos paramilitares que surgiram/intensificaram sua atuação após a intervenção militar americana no Iraque em 2003.

```
c.am <- dt.gt[region_txt == "Central America & Caribbean"]
c.am <- do.call(rbind, list(c.am[gname == "Rebel Armed Forces of Guatemala (FAR)"],
                           c.am[gname == "Sandinista National Liberation Front (FSLN)"],
                           c.am[gname == "People's Revolutionary Army (ERP) (El Salvador)"],
                           c.am[gname == "Guerrilla Army of the Poor (EGP)"],
                           c.am[gname == "Unknown"],
                           c.am[gname == "Farabundo Marti National Liberation Front (FMLN)"],
                           c.am[gname == "Contras"])))

ggplot(data = c.am, aes(factor(gname))) +
  geom_bar(position = "dodge", stat = 'count',
           color='#0099ff', fill='#33adff') +
  ylab('Número de incidentes') +
  xlab('Ano') +
```

```
ggtitle("Quantidade de ataques na América Central: grupos com maior número de incidentes") +
theme_minimal() +
theme(axis.text.x = element_text(angle = 50, hjust = 1))
```



```
c.am <- dt.gt[region_txt == "Central America & Caribbean"]
c.am <- c.am[alternative_txt == "Insurgency/Guerilla Action"]
nrow(c.am)/nrow(dt.gt[region_txt == "Central America & Caribbean"])
```

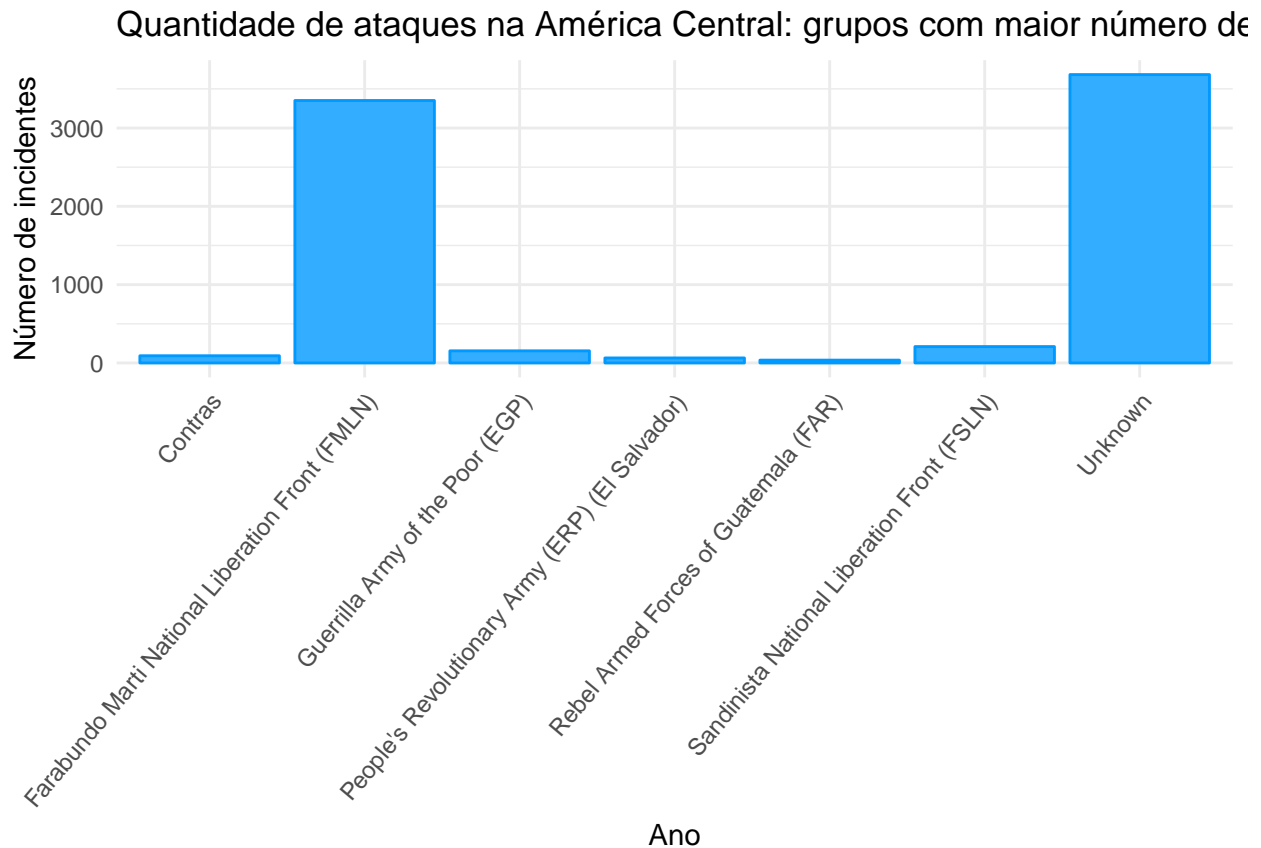
```
## [1] 0.2920696
```

## América Central e Caribe

```
c.am <- dt.gt[region_txt == "Central America & Caribbean"]
c.am <- do.call(rbind, list(c.am[gname == "Rebel Armed Forces of Guatemala (FAR)"],
c.am[gname == "Sandinista National Liberation Front (FSLN)"],
c.am[gname == "People's Revolutionary Army (ERP) (El Salvador)"],
c.am[gname == "Guerrilla Army of the Poor (EGP)"],
c.am[gname == "Unknown"],
c.am[gname == "Farabundo Marti National Liberation Front (FMLN)"],
c.am[gname == "Contras"])))

ggplot(data = c.am, aes(factor(gname))) +
geom_bar(position = "dodge", stat = 'count',
color='#0099ff',fill='#33adff') +
ylab('Número de incidentes') +
xlab('Ano') +
```

```
ggtitle("Quantidade de ataques na América Central: grupos com maior número de incidentes") +
theme_minimal() +
theme(axis.text.x = element_text(angle = 50, hjust = 1))
```



```
c.am <- dt.gt[region_txt == "Central America & Caribbean"]
c.am <- c.am[alternative_txt == "Insurgency/Guerilla Action"]
cat('Porcentagem dos ataques com o indicador Guerrilha: ',nrow(c.am)/nrow(dt.gt[region_txt == "Central America & Caribbean"]),'%\n')

## Porcentagem dos ataques com o indicador Guerrilha: 29.20696 %
```

## América Central e Caribe

### Dados com agente desconhecido

```
print.t <- c.am[gname == "Unknown", c("country_txt", "alternative_txt")]
colnames(print.t) <- c("País", "Motivo")
head(print.t)
```

```
##      País      Motivo
## 1: Guatemala Insurgency/Guerilla Action
## 2: El Salvador Insurgency/Guerilla Action
## 3: El Salvador Insurgency/Guerilla Action
## 4: Nicaragua Insurgency/Guerilla Action
## 5: Nicaragua Insurgency/Guerilla Action
## 6: Nicaragua Insurgency/Guerilla Action
```

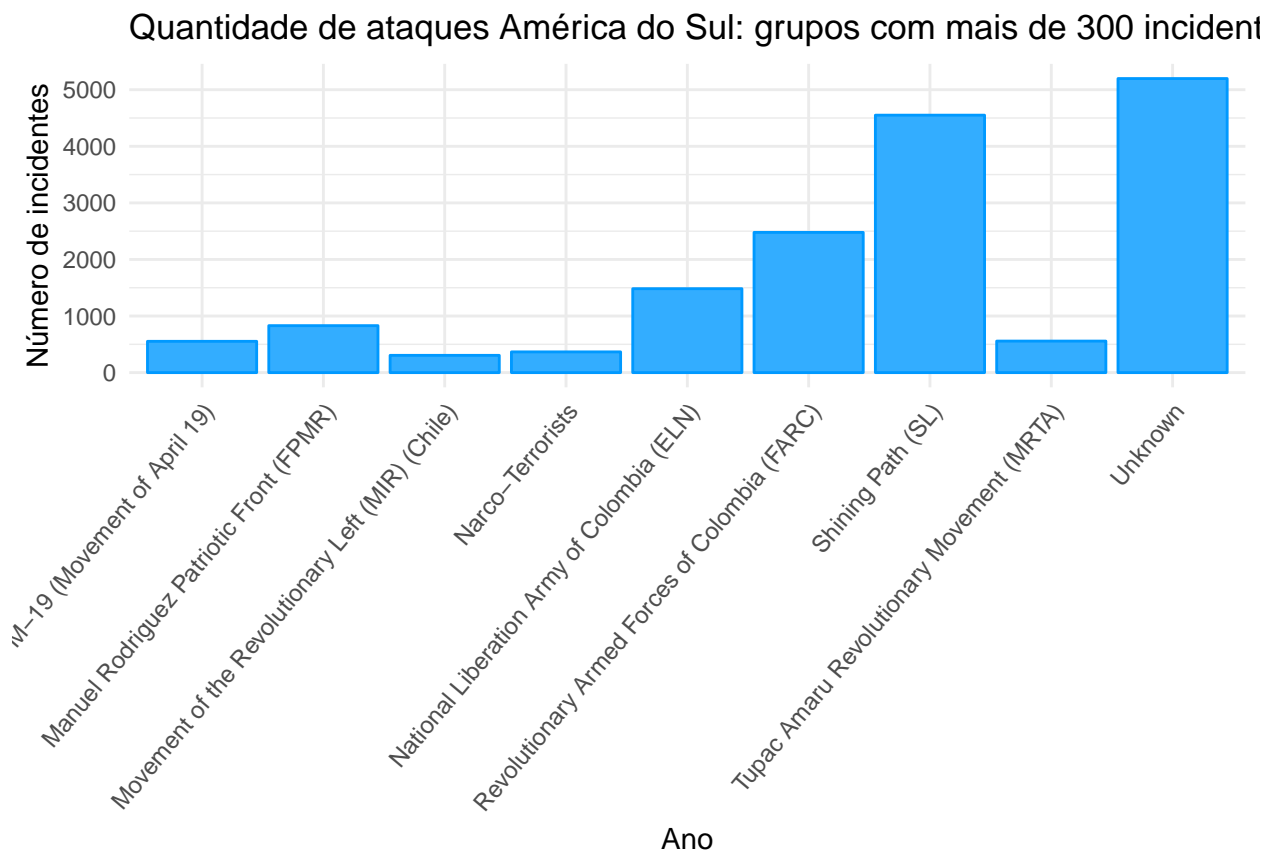


Os resultados acima indicam que boa parte das entradas no banco estão são referêntes à ataques com objetivos políticos claros. Ao análisarmos esses resultados para diferentes regiões, podemos identificar facilmente eventos políticos históricos que tem relação direta com os incidentes

## América do Sul

```
s.am <- dt.gt[region_txt == "South America"]
s.am.c <- s.am[,.N,by=c('gname')]
s.am.c <- s.am.c[N > 300]
s.am <- s.am[gname %in% s.am.c$gname]

ggplot(data = s.am, aes(factor(gname))) +
  geom_bar(position = "dodge", stat = 'count',
           color='#0099ff',fill='#33adff') +
  ylab('Número de incidentes') +
  xlab('Ano') +
  ggtitle("Quantidade de ataques América do Sul: grupos com mais de 300 incidentes") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 50, hjust = 1))
```



```
cat('Porcentagem dos ataques presentes no gráfico acima pelo total de ataques na América Central: ',nrow(s.am.c)/nrow(s.am))
```

```
## Porcentagem dos ataques presentes no gráfico acima pelo total de ataques na América Central: 0.2920696
```

## Análise dos incidentes envolvendo o Exército Provisório Irlandês (IRA)

Em seguida será feito uma análise da distribuição do tempo entre ataques terroristas causados pelo IRA. A escolha da distribuição para realizar o fit se baseia nos estudos contidos em [1]. Conforme o artigo citado, a atuação do IRA pode ser dividido em cinco fases. A primeira fase começa em 1969 e termina em 1976. Dessa forma, parte das informações referentes à primeira fase não estão contidas no dataset estudado nesse documento. No mesmo artigo, dois processos estocásticos são utilizados para tentar explicar o padrão de uso de explosivos improvisados(IED) nos ataques do IRA: um processo de Poisson e um processo de Hawkes. Há fortes indícios de que as atividades do IRA são auto-estimulantes, i.e. um ataque da organização aumenta a probabilidade de ocorrer um ataque logo em seguida [1]. Dessa forma, o artigo foca no processo de ponto auto-animado(self-exciting) de Hawkes. Não obstante, o processo de Poisson usado nesse estudo apresenta bons resultados. Sendo assim, será realizado uma tentativa de realizar um fit da distribuição exponencial aos intervalos entre ataques da primeira e segunda fase do IRA. A distribuição Gamma também será considerada.

### Estutura do IRA e contexto do conflito durante as diferentes fases

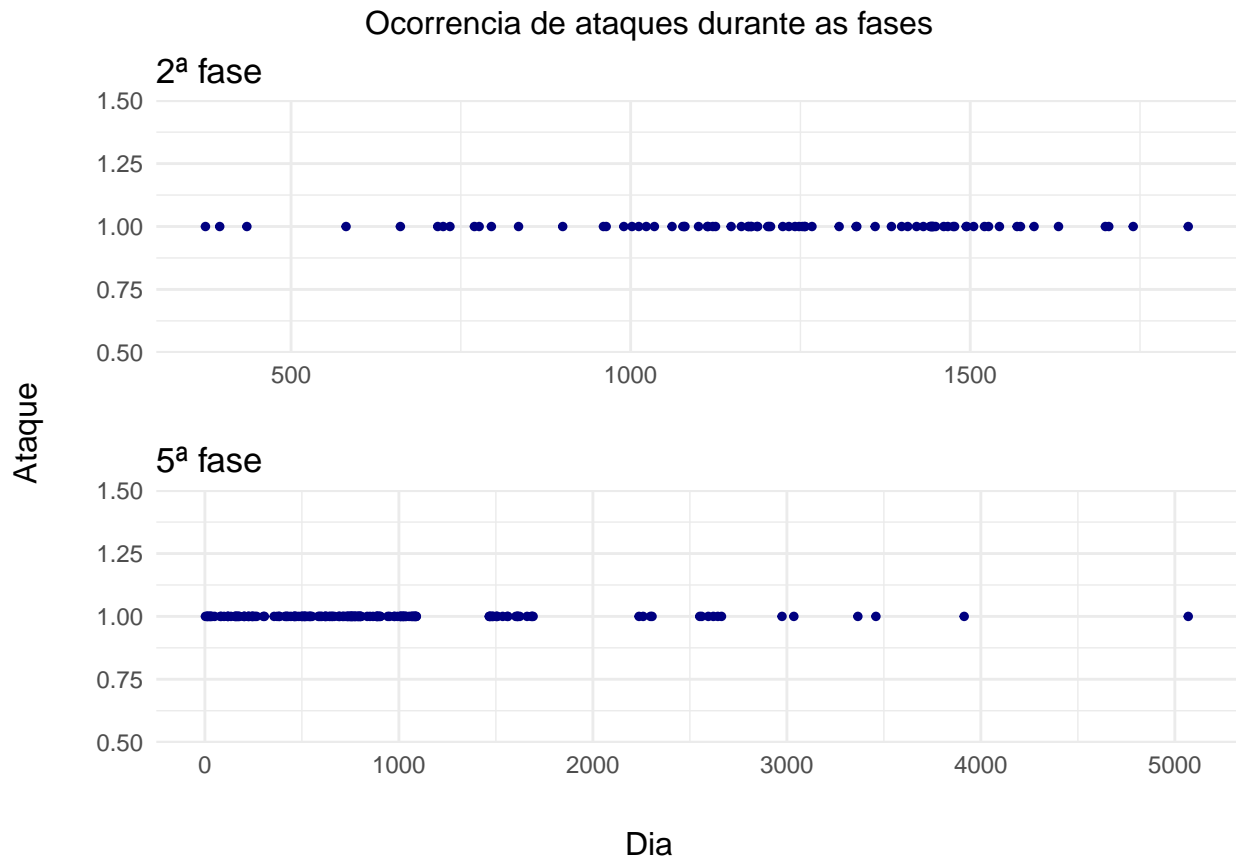
- Fase 1 (1969-1976): Estutura militar hierárquica
- Fase 2 (1977-1980): Estutura descentralizada/baseada em células
- Fase 3 (1981-1989): Debates políticos começaram
- Fase 4 (1990-1994): Acordos secretos sobre um cessar-fogo
- Fase 5 (1995-1998): Negociações de paz

### Eventos da segunda e quinta fase

```
fase2$day<- (fase2$year - 1976)*365 + (fase2$month - 1)*30 + fase2$day
dt.ira.count <- fase2[,.N,by=c('day')]
dt.ira.count[N > 1]$N <- 1
fase2.c <- dt.ira.count
g1 <- ggplot(dt.ira.count, aes(x = day, y = N)) +
  geom_point(size = 1, colour = "navyblue") +
  xlab('') +
  ylab('') +
  ggtitle("2ª fase") +
  theme_minimal()

fase5$day<- (fase5$year - 1990)*365 + (fase5$month - 1)*30 + fase5$day
dt.ira.count <- fase5[,.N,by=c('day')]
dt.ira.count[N > 1]$N <- 1
fase5.c <- dt.ira.count
g2 <- ggplot(dt.ira.count, aes(x = day, y = N)) +
  geom_point(size = 1, colour = "navyblue") +
  xlab('') +
  ylab('') +
  ggtitle("5ª fase") +
  theme_minimal()

library(gridExtra)
grid.arrange(g1,g2, left = "Ataque", bottom = "Dia", top = "Ocorrencia de ataques durante as fases")
```




### Fit da distribuição exponencial

```
g1 <- ggplot(data = fase2.c, aes(diff)) +
  stat_ecdf(colour = "navyblue") +
  stat_function(fun = pexp, args = list(rate = 0.055979), colour = "Green2") +
  xlab("") +
  ylab("")+
  ggtitle("2ª fase")
```

```
g2 <- ggplot(data = fase5.c, aes(diff)) +
  stat_ecdf(colour = "coral2") +
  stat_function(fun = pexp, args = list(rate = 0.0367244)) +
  xlab("") +
  ylab("")+
  ggtitle("5ª fase")
```

```
grid.arrange(g1,g2,ncol = 2, top = "CDF das fases x Distribuição Exponencial", bottom = "Dia", left = "Ataque")
```



## CDF das fases x Distribuição Exponencial



## QQ-plot

```
par(mfrow= c(1,2))
qqplot(y = fase2.c$diff, x = rexp(length(fase2.c$diff),rate = 0.055979), xlab = "Teórico", ylab = "Amostrado")
qqline(fase2.c$diff, distribution = function(p) qexp(p,rate = 0.055979))

qqplot(y = fase5.c$diff, x = rexp(length(fase5.c$diff),rate = 0.0367244), xlab = "Teórico", ylab = "Amostrado")
qqline(fase5.c$diff, distribution = function(p) qexp(p,rate = 0.0367244))
```



### Teste de Kolmogorov-Smirnov

```
library(stats)
library(stats4)
cat("2ª fase\n")

## 2ª fase
ks.test(fase2.c$diff, y = pexp, rate = 0.055979)

##
## One-sample Kolmogorov-Smirnov test
##
## data: fase2.c$diff
## D = 0.1041, p-value = 0.3366
## alternative hypothesis: two-sided
cat('\n D(alpha = 10 % , n = ', length(fase2.c$diff), ') = ', 0.96/sqrt(length(fase2.c$diff)))

##
## D(alpha = 10 % , n = 82 ) = 0.1060143
cat("\n5ª fase\n")

##
## 5ª fase
ks.test(fase5.c$diff, y = pexp, rate = 0.0367244)

##
## One-sample Kolmogorov-Smirnov test
##
## data: fase5.c$diff
```

```
## D = 0.40922, p-value < 2.2e-16
## alternative hypothesis: two-sided
cat('\n D(alpha = 10 % , n = ',length(fase5.c$diff),') =', 0.96/sqrt(length(fase5.c$diff)))

##
## D(alpha = 10 % , n = 187 ) = 0.07020215
```


## Fit distribuição Gamma

```
fase2.c.d <- data.table(diff = diff(fase2.c$day), fase = "2")
fase5.c.d <- data.table(diff = diff(fase5.c$day), fase = "5")
g1 <- ggplot(data = fase2.c.d, aes(diff)) +
  stat_ecdf(colour = "navyblue") +
  stat_function(fun = pgamma, args = list(shape = 0.82741053, rate = 0.04632389), colour = "Green2") +
  xlab("") +
  ylab("")+
  ggtitle("2ª fase")

g2 <- ggplot(data = fase5.c.d, aes(diff)) +
  stat_ecdf(colour = "coral2") +
  stat_function(fun = pgamma, args = list(shape = 0.428446297, rate = 0.01574122)) +
  xlab("") +
  ylab("")+
  ggtitle("5ª fase")

grid.arrange(g1,g2,ncol = 2, top = "CDF das fases x Distribuição Gamma", bottom = "Dia", left = "Percentagem")
```



## CDF das fases x Distribuição Gamma



## QQ-plots

```
par(mfrow= c(1,2))
qqplot(y = fase2.c$diff, x = rgamma(length(fase2.c$diff),shape = 0.82741053, rate = 0.04632389), xlab = "Dia", ylab = "Percentil")
qqline(fase2.c$diff, distribution = function(p) qgamma(p,shape = 0.82741053, rate = 0.04632389))

qqplot(y = fase5.c$diff, x = rgamma(length(fase5.c$diff),shape = 0.428446297, rate = 0.01574122), xlab = "Dia", ylab = "Percentil")
qqline(fase5.c$diff, distribution = function(p) qgamma(p,shape = 0.428446297, rate = 0.01574122))
```



### Teste de Kolmogorov-Smirnov

```
library(stats)
library(stats4)
cat("2ª fase\n")
```

```
## 2ª fase
```

```
ks.test(fase2.c$diff, y = pgamma, shape = 0.82741053, rate = 0.04632389)
```

```
##
## One-sample Kolmogorov-Smirnov test
##
## data: fase2.c$diff
## D = 0.082104, p-value = 0.6381
## alternative hypothesis: two-sided
```

```
cat('\n D(alpha = 10 % , n = ',length(fase2.c$diff),') =', 1.22/sqrt(length(fase2.c$diff)))
```

```
##
## D(alpha = 10 % , n = 82 ) = 0.1347265
```

```
cat("\n5ª fase\n")
```

```
##
## 5ª fase
```

```
ks.test(fase5.c$diff, y = pgamma, shape = 0.428446297, rate = 0.01574122)
```

```
##
## One-sample Kolmogorov-Smirnov test
##
## data: fase5.c$diff
```



```
## D = 0.24234, p-value = 5.777e-10
## alternative hypothesis: two-sided
cat('\n D(alpha = 10 % , n = ',length(fase5.c$diff),') =', 0.96/sqrt(length(fase5.c$diff)))

##
## D(alpha = 10 % , n = 187 ) = 0.07020215
```

Tanto o fit da distribuição gamma quanto da exponencial foram melhores na segunda fase dos ataques do que na última fase. Isso reflete de forma direta os objetivos e a estrutura da organização nesses diferentes momentos históricos: pelo fato da organização do IRA na segunda fase estar dividida em células, pode-se observar uma independência maior entre os ataques; já na última fase do conflito, os incidentes são intercalados com negociações de paz e discussões secretas com o governo britânico. Os ataques nessa etapa servem um propósito de tentar ganhar vantagem nas negociações e por isso possuem um padrão mais dependente. [1]

## Modelo de Hawkes

$$\lambda(t) = \mu + k_0 \sum_{t > t_i} g(t - t_i; \omega)$$

$$\log L = \sum_{i=1}^N \left[ \log \left( \mu + k_0 \sum_{t_i > t_j} \omega e^{-\omega(t_i - t_j)} \right) + k_0 \left( e^{-\omega(T - t_i)} - 1 \right) \right] - \mu T.$$

O modelo de Hawkes leva em consideração os padrões auto-estimulantes presentes nos eventos do IRA. A função de log likelihood foi aplicada como presente em [1]

```
fase2$day<- (fase2$year - 1976)*365 + (fase2$month - 1)*30 + fase2$day
dt.ira.count <- fase2[,.N,by=c('day')]
dt.ira.count[N > 1]$N <- 1

elist <- dt.ira.count$day
tlist <- 0:(max(elist))
n <- length(elist)
loglik <- function(params, arrivals){
  k0 <- params[1]
  omega <- params[2]
  mu <- params[3]
  term_1 <- -mu*arrivals[n]
  term_2 <- k0*sum((exp(-omega * (arrivals[n] - arrivals)) - 1))
```

```

    Ai      <- c(0, sapply(2:n, function(z) {
      sum(omega*exp( -omega * (arrivals[z]- arrivals[1:(z - 1)])))
    }))
    term_3  <- sum(log( mu + k0 * Ai))
  return(-term_1- term_2 -term_3)
}

case1_solution1 <- optim(c(0.1,0.8,0.5), loglik, method = "Nelder-Mead", arrivals = unlist(elist))
cat("Resultados do MLE: ",paste( c("k0", "omega", "mu"), round(case1_solution1$par,2), sep=" = "))

## Resultados do MLE:  k0 = 0.9 omega = 0.01 mu = 0.01

estimated_intensity <- function(params, arrivals){
  k0 <- params[1]
  omega <- params[2]
  mu <- params[3]
  Ai      <- c(0, sapply(2:n, function(z) {
    sum(omega*exp( -omega * (arrivals[z]- arrivals[1:(z - 1)])))
  }))
  return(mu + k0 *Ai)
}

vlambda <- function(tlist) data.frame( y = unlist(lapply(tlist, function(t)lambda(t,mu = 0.01,k0 = 0.9,
x = tlist)

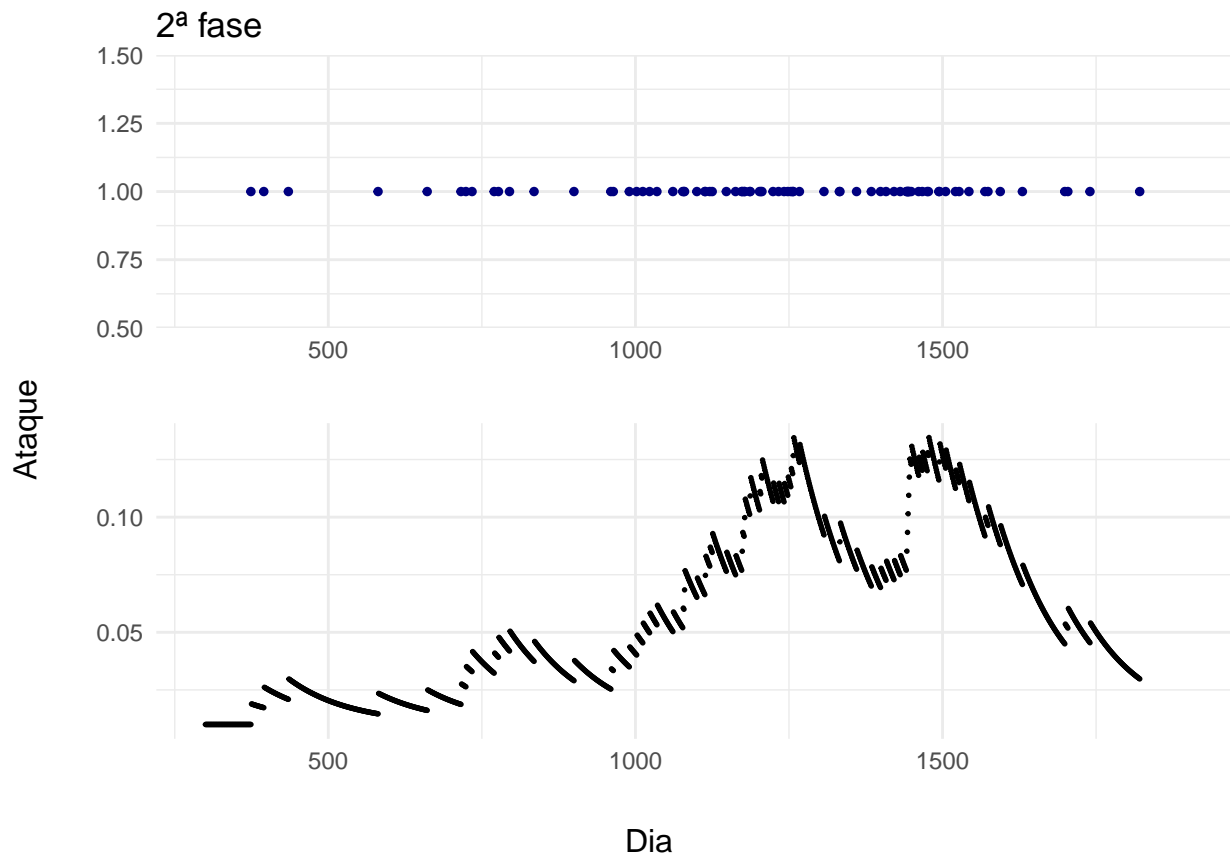
z <- vlambda(c(1:max(dt.ira.count)))

g1 <- ggplot(dt.ira.count, aes(x = day, y = N)) +
  geom_point(size = 1, colour = "navyblue") +
  scale_x_continuous(limits = c(300,1900)) +
  xlab('') +
  ylab("") +
  ggtitle("2ª fase") +
  theme_minimal()

g2 <- ggplot() +
  scale_x_continuous(limits = c(300,1900)) +
  geom_point(data = z, aes(x = x, y = y),size = .3) +
  xlab('') +
  ylab("") +
  theme_minimal()

grid.arrange(g1,g2, left = "Ataque", bottom = "Dia")

```



```
fase5$day<- (fase5$year - 1990)*365 + (fase5$month - 1)*30 + fase5$day
dt.ira.count <- fase5[,.N,by=c('day')]
dt.ira.count[N > 1]$N <- 1

elist <- dt.ira.count$day
tlist <- 0:(max(elist))
n <- length(elist)
loglik <- function(params, arrivals){
  k0 <- params[1]
  omega <- params[2]
  mu <- params[3]
  term_1 <- -mu*arrivals[n]
  term_2 <- k0*sum((exp(-omega * (arrivals[n] - arrivals)) - 1))
  Ai <- c(0, sapply(2:n, function(z) {
    sum(omega*exp(-omega * (arrivals[z]- arrivals[1:(z - 1)])))
  }))
  term_3 <- sum(log( mu + k0 * Ai))
  return(-term_1- term_2 -term_3)
}

case1_solution1 <- optim(c(0.9,0.1,4.5), loglik, method = "Nelder-Mead", arrivals = unlist(elist))
cat("Resultados do MLE: ",paste( c("k0", "omega", "mu"), round(case1_solution1$par,2), sep=" = "))

## Resultados do MLE: k0 = 0.92 omega = 0.04 mu = 0
estimated_intensity <- function(params, arrivals){
  k0 <- params[1]
```

```

omega  <- params[2]
mu     <- params[3]
Ai     <- c(0, sapply(2:n, function(z) {
sum(omega*exp( -omega * (arrivals[z]- arrivals[1:(z - 1)])))
}))
return(mu + k0 *Ai)
})


vlambda <- function(tlist) data.frame( y = unlist(lapply(tlist, function(t)lambda(t,mu = 0,k0 = 0.92, on
x = tlist)
z <- vlambda(c(1:max(dt.ira.count)))

g1 <- ggplot(dt.ira.count, aes(x = day, y = N)) +
  geom_point(size = 1, colour = "navyblue") +
  scale_x_continuous(limits = c(300,1900)) +
  xlab('') +
  ylab('') +
  ggtitle("5ª fase") +
  theme_minimal()

g2 <- ggplot() +
  scale_x_continuous(limits = c(300,1900)) +
  geom_point(data = z, aes(x = x, y = y),size = .3) +
  xlab('') +
  ylab('') +
  theme_minimal()

grid.arrange(g1,g2, left = "Ataque", bottom = "Dia")

```



Os parâmetros observados para o modelo de Hawkes refletem os resultados dos parâmetros das distribuições: a segunda fase possui o parâmetro de ruído do fundo ( $\mu$ ) maior do que a quinta fase, indicando que nessa última os eventos são mais dependentes. Os parâmetros relacionados ao tamanho da sequência de ataques e a escalação da quantidade de ataques dado um evento inicial ( $\omega$  e  $k_0$  respectivamente) são maiores na última fase do conflito, reforçando a hipótese de maior dependência entre os ataques. [1]

## Referências

- [1] TENCH, Stephen, FRY, Hannah. GILL, Paul. Spatio-temporal patterns of IED usage by the Provisional Irish Republican Army
- [2] TRIVEDI, Kishor. Probability, Statistics and Queuing with Computer Science Applications